

Projekt Energieverbrauch

| Siamak Goudarzi 2026-01-14

Fragestellung

Dataset

Variablentyp

Hypothesen

Schritt 1: Daten laden und -aufbereitung

Schritt 2: Datenbeschreibung

| Zusammenfassungen für numerische Variablen: DS_Energie

Interpretation der Ergebnisse

Schritt 3: Visuelle Analyse und Ausreißererkennung

| Boxplot: ~ Herkömmlich.. + Neuartig..kWh..

Interpretation der Ergebnisse

Schritt 4: Anforderungs- und Annahmenprüfung

| Quantile-Comparison Plot: Herkömmlich..

Interpretation der Ergebnisse

| Quantile-Comparison Plot: Neuartig..kWh..

Interpretation der Ergebnisse

| Test auf Normalverteilung: ~Herkömmlich..

Interpretation der Ergebnisse

Die Entscheidung, welchen Test man wählen soll

| Levenes Test: Consumption ~ Method

Interpretation der Ergebnisse

Schritt 5: Inferenztests

| Independent-Samples t-Test: Consumption~Method

| Wilcoxon Test: Consumption ~ Method

Interpretation der Ergebnisse

Abschließende Analyse

Projekt Energieverbrauch

Author: Siamak Goudarzi

2026-01-14

Fragestellung

Ist die neue Methode wirksam bei der Reduzierung des Energieverbrauchs?

Dataset

Beinhaltet 100 unabhängige Beobachtungen (50 für jede Methode).

Variablentyp

Kontinuierliche Größe (Einheit: kWh)

Hypothesen

Hypothese Null (H_0):

Der Energieverbrauch der neuen Methode ist gleich oder höher als der der alten Methode. ($\mu_{1-1} \geq \mu_{2-1}$)

Alternativhypothese (H_1):

Der Energieverbrauch der neuen Methode ist signifikant geringer als der der alten Methode. ($\mu_{1-1} < \mu_{2-1}$)

Schritt 1: Daten laden und -aufbereitung

Formatfehler behoben:

Die zusätzliche Einheitenzeile ([kWh]) wurde entfernt, damit die Variablen von R korrekt erkannt werden können.

Datentyp-Umwandlung:

Die Spalten wurden von Text in numerische Werte (Numeric) konvertiert, damit die statistischen Menüs aktiviert werden können.

Stacking:

Die Daten wurden für die Durchführung vergleichender Tests (z. B. Levene- und t-Test) in ein standardisiertes Gruppenformat überführt.

```
> DS_Energie <- readXL("/home/siamak/Downloads/download (4)/Daten_KW03.xlsx",  
+   rownames=FALSE, header=TRUE, na="", sheet="2_Energieverbrauch",
```

```
+ stringsAsFactors=TRUE)
```

```
> library(abind, pos=17)
```

```
> library(e1071, pos=18)
```

Schritt 2: Datenbeschreibung

Zusammenfassung:

Berechnen Sie den Mittelwert und den Median beider Gruppen, um einen ersten Eindruck vom Konsumverhalten der jeweiligen Gruppe zu erhalten.

Zusammenfassungen für numerische Variablen: DS_Energie

```
> numSummary(DS_Energie[,c("Herkömmlich..", "Neuartig..kWh.."), drop=FALSE],
+ statistics=c("mean", "sd", "IQR", "quantiles"), quantiles=c(0,.25,.5,.75,1))
```

	mean	sd	IQR	0%	25%	50%	75%
Herkömmlich..	347.4444	53.44699	68.4575	204.22	311.8125	348.470	380.2700
Neuartig..kWh..	313.5530	52.27818	49.6900	239.01	279.7225	306.265	329.4125
	100%	n					
Herkömmlich..	451.46	50					
Neuartig..kWh..	478.73	50					

Interpretation der Ergebnisse

Mittelwert:

Alte Methode (Herkömmlich): 347,44

Neue Methode (Neuartig): 313,55

>> Erste Interpretation:

Die neue Methode reduzierte den Energieverbrauch im Durchschnitt um etwa 34 Einheiten. Dies ist ein positiver Unterschied.

Median (Median / 50%):

Alte Methode: 348,47

Neue Methode: 306,26

Anmerkungen:

Der Median der neuen Methode ist deutlich niedriger, was darauf hindeutet, dass die meisten Daten der neuen Methode auf einem niedrigeren Niveau liegen.

Streuung (Standardabweichung und Interquartilsabstand):

Die Standardabweichung (SD) beider Methoden liegt sehr nahe beieinander (etwa 52 bzw. 53). Das ist erfreulich! Denn eine der Voraussetzungen des t-Tests (Varianzhomogenität) ist wahrscheinlich erfüllt.

Der Interquartilsabstand (IQR) ist bei der neuen Methode jedoch geringer (49,69 gegenüber 68,45), was darauf hindeutet, dass die neue Methode im Energieverbrauch „stabiler“ bzw. fokussierter ist.


Schritt 3: Visuelle Analyse und Ausreißererkennung

Begründung für die Auswahl:

Der Boxplot ist das beste Werkzeug, um Ausreißer zu identifizieren und die Verteilung zweier Gruppen visuell zu vergleichen.

Boxplot: ~ Herkömmlich.. + Neuartig..kWh..

```
> Boxplot( ~ Herkömmlich.. + Neuartig..kWh.., data=DS_Energie,  
+ id=list(method="y"))
```



plot of chunk unnamed-chunk-6

```
[1] "13" "21" "39" "45" "47"
```

Interpretation der Ergebnisse

Lageunterschied:

Die Box für die Neuartig-Methode (neu) liegt deutlich tiefer als die Box für die Herkömmlich-Methode (alt).

Auch die dicke Linie in der Mitte der Box (Median) liegt bei der neuen Methode wesentlich tiefer. Das bedeutet, dass die neue Methode in den meisten Fällen

weniger Energie verbraucht.

Streuung:

Die Boxgröße der neuen Methode (der Abstand zwischen dem ersten und dritten Quartil) ist kleiner.

Dies deutet darauf hin, dass der Energieverbrauch in der neuen Methode „stabiler“ und besser vorhersagbar ist.

Ausreißer:

Bei der alten Methode gibt es einen Ausreißer ganz unten (Nummer 13).

Bei der neuen Methode gibt es vier Ausreißer ganz oben (Nummern 47, 39, 21 und 45).

Schritt 4: Anforderungs- und Annahmenprüfung

Nach der Prüfung auf visuelle Unterschiede müssen wir prüfen, ob wir einen t-Test durchführen dürfen. Dazu müssen wir feststellen, ob die Datenverteilung normalverteilt ist oder nicht.

4.1. Normalitätstest:


Methoden: Shapiro-Wilk-Test und QQ-Plot.

Voraussetzung:

Für die Anwendung des t-Tests müssen die Daten normalverteilt sein.

Quantile-Comparison Plot: Herkömmlich..

```
> with(DS_Energie, qqPlot(Herkömmlich., dist="norm", id=list(method="y", n=2,  
+ labels=rownames(DS_Energie))))
```



plot of chunk unnamed-chunk-7

```
[1] 13 10
```

Interpretation der Ergebnisse

Dieses Diagramm zeigt Folgendes:

Fast alle Datenpunkte liegen auf der geraden blauen Linie und sind gut innerhalb des schattierten Bereichs (Konfidenzintervall) eingeschlossen.

Lediglich ein Punkt (Nummer 13) am unteren Rand des Diagramms weicht


geringfügig von der Linie ab, diese Abweichung ist jedoch so gering, dass sie die Gesamtverteilung nicht von der Normalverteilung ablenkt.

>> Ergebnis:

Diese Grafik bestätigt, dass die Daten der alten Methode wahrscheinlich normalverteilt sind.

Quantile-Comparison Plot: Neuartig..kWh..

```
> with(DS_Energie, qqPlot(Neuartig..kWh.., dist="norm", id=list(method="y",  
+ n=2, labels=rownames(DS_Energie))))
```



plot of chunk unnamed-chunk-8


```
[1] 47 39
```

Interpretation der Ergebnisse

Dieses Diagramm zeigt eine andere Situation:

Bei mittleren Werten (zwischen 250 und 350) liegen die Punkte gut auf der Geraden.

Auf der rechten und oberen Seite des Diagramms weichen mehrere Punkte (insbesondere 47 und 39) deutlich von der Geraden ab und liegen vollständig außerhalb des schattierten Bereichs.

Diese Punkte deuten auf eine Rechtsschiefe und das Vorhandensein von Ausreißern mit sehr hohen Werten hin.

>> Ergebnis:

Dieses Diagramm zeigt deutlich, dass die Daten wahrscheinlich nicht normalverteilt sind.

Test auf Normalverteilung: ~Herkömmlich..

```
> normalityTest(~Herkömmlich.., test="shapiro.test", data=DS_Energie)
```

Shapiro-Wilk normality test

data: Herkömmlich..

W = 0.98862, p-value = 0.9087

```
> normalityTest(~Neuartig..kWh.., test="shapiro.test", data=DS_Energie)
```

Shapiro-Wilk normality test

data: Neuartig..kWh..

W = 0.8955, p-value = 0.0003423

Interpretation der Ergebnisse

Traditionelle Methode (Herkömmlich):

p-Wert = 0,9087.

Da dieser Wert deutlich größer als 0,05 ist, wird die Nullhypothese (H_0) der Normalverteilung bestätigt. Die Daten der traditionellen Methode sind perfekt normalverteilt.

Neue Methode (Neuartig):

p-Wert = 0,0003423.

Da dieser Wert deutlich kleiner als 0,05 ist, wird die Annahme der Normalverteilung verworfen. Dies bedeutet, dass die Daten der neuen Methode (aufgrund der gleichen vier Ausreißer, die wir bereits im Boxplot und QQ-Plot gesehen haben) nicht statistisch normalverteilt sind.

4.2. Test auf Varianzhomogenität:

Methode: Levene-Test (Mittelwert = Median).

Begründung:

Da eine der Gruppen nicht normalverteilt war, ist der Levene-Test, der auf dem Median basiert, deutlich robuster und genauer als der Bartlett-Test.

Die Entscheidung, welchen Test man wählen soll

Wenn die Daten nicht normalverteilt sind, gibt es drei Möglichkeiten:

Erste Möglichkeit:

Anwendung eines nichtparametrischen Tests (Wilcoxon-Test), der nicht von der Normalverteilung abhängt.

Zweite Möglichkeit:

Transformation

```
> DS_Energie_Stacked <- stack(DS_Energie[, c("Herkömmlich..",
+   "Neuartig..kWh..")])
> names(DS_Energie_Stacked) <- c("Consumption", "Method")
```

Levenes Test: Consumption ~ Method

```
> Tapply(Consumption ~ Method, var, na.action=na.omit,  
+ data=DS_Energie_Stacked) # variances by group
```

Herkömmlich..	Neuartig..kWh..
2856.581	2733.008

```
> leveneTest(Consumption ~ Method, data=DS_Energie_Stacked, center="median")
```

```
Levene's Test for Homogeneity of Variance (center = "median")  
      Df F value Pr(>F)  
group  1  0.9829 0.3239  
      98
```

Interpretation der Ergebnisse

Numerische Ergebnisse:

F-Wert = 0,9829 und p-Wert = 0,3239.

Da der p-Wert größer als 0,05 ist, verwerfen wir die Nullhypothese (H_0) der Gleichheit der Varianzen nicht.

>> Ergebnis:

Die Varianz (Streuung) des Energieverbrauchs ist sowohl bei der alten als auch bei der neuen Methode statistisch gleich (Varianzhomogenität).

Schritt 5: Inferenztests

Endgültige Entscheidung über die Testauswahl:

Den bisherigen Ergebnissen zufolge:

Die Daten waren nach der neuen Methode nicht normalverteilt (Shapiro-Test).

Die Varianzen sind gleich (Levene-Test).

Stichprobenumfang: $n = 50$ pro Gruppe (insgesamt 100 Datensätze).

>> Endgültige Entscheidung:

Da Ihre Stichprobe groß ist ($n > 30$), wird üblicherweise der t-Test

verwendet, da er bei großen Stichproben robust gegenüber Abweichungen von der Normalverteilung ist.

Um jedoch einen stärkeren Beweis zu erbringen, führen wir beide Tests durch. Stimmen die Ergebnisse beider Tests überein, ist die Behauptung zulässig.

5.1. Unabhängiger t-Test (parametrisch):

Grund für die Auswahl: Vergleich der Mittelwerte zweier unabhängiger Gruppen bei gleichen Varianzen.

Independent-Samples t-Test: Consumption~Method

```
> t.test(Consumption~Method, alternative='greater', conf.level=.95,
+ var.equal=TRUE, data=DS_Energie_Stacked)
```

Two Sample t-test

```
data: Consumption by Method
t = 3.2054, df = 98, p-value = 0.0009105
alternative hypothesis: true difference in means between group Herkömmlich.. and
group Neuartig..kWh.. is greater than 0
95 percent confidence interval:
 16.33412      Inf
sample estimates:
mean in group Herkömmlich.. mean in group Neuartig..kWh..
      347.4444              313.5530
```

5.2. Wilcoxon- / Mann-Whitney-U-Test (nichtparametrisch):

Begründung für die Wahl: Dieser Test setzt keine Normalverteilung voraus, und da unsere Daten (neue Methode) nicht normalverteilt waren, dient dieser Test als abschließendes Bestätigungsdokument.

Wilcoxon Test: Consumption ~ Method

```
> Tapply(Consumption ~ Method, median, na.action=na.omit,
+ data=DS_Energie_Stacked) # medians by group
```

```
Herkömmlich.. Neuartig..kWh..
      348.470      306.265
```

```
> wilcox.test(Consumption ~ Method, alternative="greater",
```

```
+ data=DS_Energie_Stacked)
```

Wilcoxon rank sum test with continuity correction

data: Consumption by Method

W = 1767, p-value = 0.000185

alternative hypothesis: true location shift is greater than 0

Interpretation der Ergebnisse

p-Wert:

Im t-Test wurde ein p-Wert von 0,0009 ermittelt.

Der Wilcoxon-Test ergab einen p-Wert von = 0,0001.

Beide Werte liegen deutlich unterhalb der Standardfehlergrenze (0,05). Das bedeutet, dass die Wahrscheinlichkeit, dass dieser Unterschied im Energieverbrauch zufällig ist, nahezu null ist.

Abschließende Analyse

Wir verwerfen die Nullhypothese (H_0). Es gibt sehr starke statistische Belege dafür, dass der Energieverbrauch der neuen Methode (Neuartig) signifikant geringer ist als der der alten Methode (Herkömmlich).